LE DÉFI · RETROUVER UN TEXTE CACHÉ

Le flag avait disparu.
Il restait des nombres.

FICHIER FOURNI

Dockerfile.json

```
model: "gpt2"
inputs_embeds:
  [ 0.1145, -0.3451, 0.2239, … ]
  [ … ]
  …
```

Extrait arrondi des premières valeurs.

24 groupes de nombres

768 nombres par groupe

Chaque groupe représente un morceau du texte, avec une information sur sa position.

L'IDÉE À RETENIR

Notre mission : **reconstituer le texte d'origine.**

COMPRENDRE · QU'EST-CE QU'UN EMBEDDING ?

Un morceau de texte.
Une ligne dans une table.

MORCEAU DE TEXTE

BA

Un « token »

→

TABLE PUBLIQUE DE GPT-2

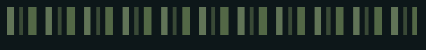
BA		768 nombres
26		768 nombres
{		768 nombres

Schéma : les barres représentent des listes de nombres.

Dans ce fichier, on ajoute aussi : LA POSITION DU MORCEAU — Pour distinguer le premier, le deuxième, le troisième…

L'IDÉE À RETENIR

Le morceau de texte et sa position viennent de **deux tables connues.**

LE DÉCLIC · ON CONNAÎT LES DEUX TABLES

Retirer la position.
Retrouver le morceau.

01

Lire un groupe

nombres du morceau

+ nombres de sa position

Les nombres reçus.

02

Retirer la position

nombres du morceau

~~nombres de sa position~~

Elle est dans la table publique.

03

Comparer à la table

BA ✓

Le morceau le plus proche est retrouvé.

L'IDÉE À RETENIR

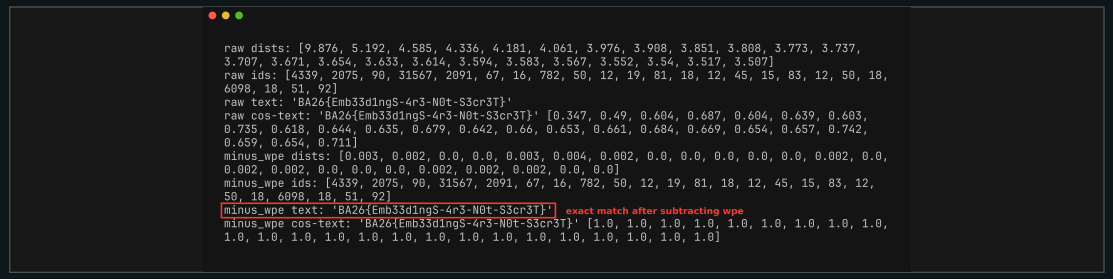
Recommencer pour les 24 groupes, puis assembler les morceaux.

LA PREUVE · LES 24 MORCEAUX S'ASSEMBLENT

Les nombres ont retrouvé leurs lettres.

BA	26	{	Emb	33	d	1	ng	S	…	}

BA26{Emb33d1ngS-4r3-N0t-S3cr3T}



```
raw dists: [9.876, 5.192, 4.585, 4.336, 4.181, 4.061, 3.976, 3.908, 3.851, 3.808, 3.773, 3.737,
3.707, 3.671, 3.654, 3.633, 3.614, 3.594, 3.583, 3.567, 3.552, 3.54, 3.517, 3.507]
raw ids: [4339, 2075, 90, 31567, 2091, 67, 16, 782, 50, 12, 19, 81, 18, 12, 45, 15, 83, 12, 50, 18,
6098, 18, 51, 92]
raw text: 'BA26{Emb33d1ngS-4r3-N0t-S3cr3T}'
raw cos-text: 'BA26{Emb33d1ngS-4r3-N0t-S3cr3T}' [0.347, 0.49, 0.604, 0.687, 0.604, 0.639, 0.603,
0.735, 0.618, 0.644, 0.635, 0.679, 0.642, 0.66, 0.653, 0.661, 0.684, 0.669, 0.654, 0.657, 0.742,
0.659, 0.654, 0.711]
minus_wpe dists: [0.003, 0.002, 0.0, 0.0, 0.003, 0.004, 0.002, 0.0, 0.0, 0.0, 0.0, 0.0, 0.002, 0.0,
0.002, 0.002, 0.0, 0.0, 0.0, 0.002, 0.002, 0.002, 0.0, 0.0]
minus_wpe ids: [4339, 2075, 90, 31567, 2091, 67, 16, 782, 50, 12, 19, 81, 18, 12, 45, 15, 83, 12,
50, 18, 6098, 18, 51, 92]
minus_wpe text: 'BA26{Emb33d1ngS-4r3-N0t-S3cr3T}'   exact match after subtracting wpe
minus_wpe cos-text: 'BA26{Emb33d1ngS-4r3-N0t-S3cr3T}' [1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0,
1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0]
```

PREUVE CONSERVÉE · CLIQUER POUR AGRANDIR

24 / 24

Morceaux retrouvés.
Correspondances presque exactes
après retrait de la position.

Solve : Claude

L'IDÉE À RETENIR

Dans ce cas, transformer le texte en nombres **ne protégeait pas son contenu.**