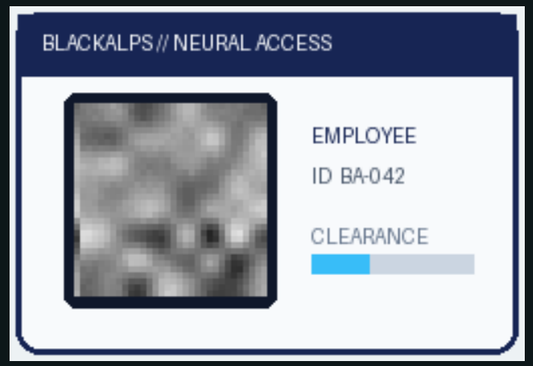
LE DÉFI · UNE IMAGE DÉCIDE DES DROITS

Pour entrer comme admin, il faut convaincre un modèle.

BADGE FOURNI



Classé « EMPLOYEE ».

LE SCANNER RENVOIE DES SCORES

EMPLOYEE	
INVALID	
ADMIN	≥ 99,5 %

Le seuil à dépasser pour obtenir l’accès.

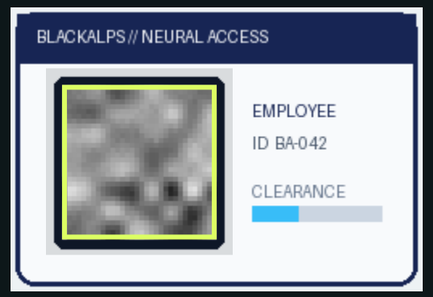
L’IDÉE À RETENIR

On peut modifier l’image et observer **le score renvoyé à chaque essai.**

L’INDICE · LE PRÉTRAITEMENT EST FOURNI, LE MODÈLE RESTE CACHÉ

Le modèle ne voit qu’un carré.
Nous contrôlons toutes ses cases.

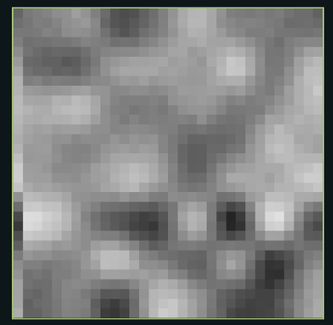
IMAGE FOURNIE · 256 × 176



Le scanner découpe
la zone encadrée.

→

CARRÉ · 96 × 96



Niveaux de gris,
puis moyenne par bloc de 3 × 3.

→

ENTRÉE DU MODÈLE · 32 × 32



Un bloc de neuf pixels identiques
fixe la valeur d’une case.

L’IDÉE À RETENIR

Modifier le bon carré suffit : **le reste du badge n’est pas vu par le modèle.**

LE DÉCLIC · UTILISER LE RETOUR DU MODÈLE

Tester des variations par paires. Suivre le meilleur signal.

POINT DE DÉPART Le badge employé. Les images aléatoires étaient surtout classées « INVALID ».

01

Varier dans les deux sens

```
badge + variation
badge − variation
```

20 directions essayées par paires :
40 images dans un lot.

→

02

Comparer les retours

MOINS ADMIN | PLUS ADMIN

Les différences de scores
indiquent les directions utiles.

→

03

Mettre le badge à jour

↻

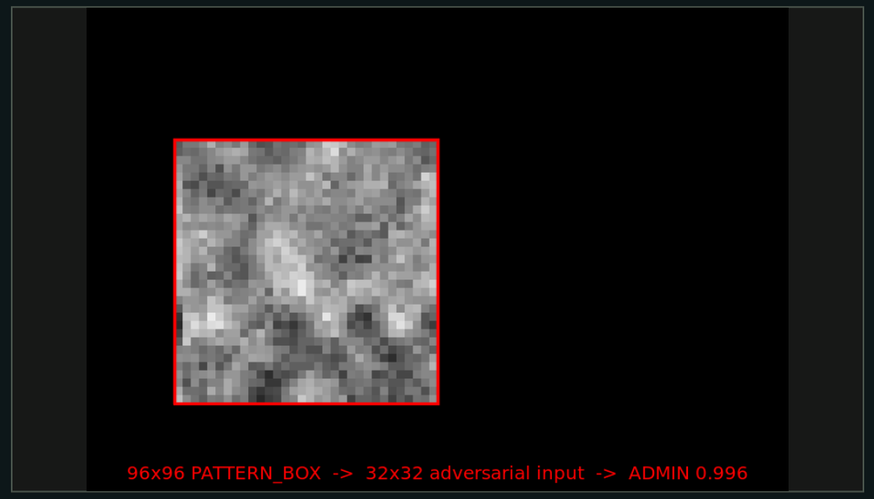
Combiner ces directions,
faire un pas, puis recommencer.

L'IDÉE À RETENIR

L'agent apprend **comment changer l'image** en observant la réponse du modèle.

LE RÉSULTAT · LE MODÈLE ACCORDE L’ACCÈS

Le badge ressemblait à du bruit.
Le modèle a reconnu le patron.



PREUVE CONSERVÉE · CLIQUER POUR AGRANDIR

SCORE ADMIN RAPPORTÉ DANS LE JOURNAL

99,6 %

Seuil demandé : 99,5 %.

ACCÈS ACCORDÉ

`BA26{r3ached_1h3_t0P}`

L’IDÉE À RETENIR

Une décision d’accès fondée sur une image peut être **pilotée par les scores exposés.**